SAMSUNG

UNIVERSIDAD DE MONRERREY

Sistema de Segmentación y Detección de Lesiones Cutáneas mediante YOLO/SAM

P R O Y E C T O
F I N A L

PARA:
SAMSUNG INNOVATION CAMPUS

PRESENTA:
Sanchez Ruiz Ruben Dario
L21020441@veracruz.tecnm.mx
Kevin Daniel Flores Mayoral
L21020287@veracruz.tecnm.mx

Asesor:
Mtro. Eduardo de Avila Armenta

2026

Índice

1. Marco metodológico **6**
1.1. Introducción 6
1.2. Antecedentes del problema 7
1.3. Planteamiento del problema 7
1.4. Objetivos 7
1.4.1. Objetivo general 7
1.4.2. Objetivos específicos 7
1.5. Justificación 8
1.5.1. Impacto Social 8
1.5.2. Impacto Tecnológico 8
1.5.3. Impacto Educativo 8
1.6. Alcances y limitaciones 8
1.6.1. Alcances 8
1.6.2. Limitaciones 8

2. Marco Referencial: **9**

3. Marco Teórico **11**
3.1. Cáncer de Piel 11
3.2. No melanoma 11
3.3. Melanoma 11
3.4. Método ABCDE 12
3.5. Yolo y Yolov11 12
3.6. Ultralytics 12
3.7. PyTorch y CUDA 12
3.8. Segment Anything Model (SAM) 12

4. DESARROLLO **13**
4.1. Dataset Skin Cancer MNIST: HAM10000 : 13
4.2. Representación gráfica de la idea del Proyecto 14
4.2.1. Con SAM: 14
4.2.2. Sin SAM: 15

5. Entrenamiento **16**
5.1. Con SAM 16
5.2. Sin SAM 17

6. Resultados y comparación **18**
6.1. Evaluación de Entrenamientos 18
6.2. Entrenamiento con SAM 18
6.2.1. Curva F1 – Confianza 21
6.2.2. Curva Precisión – Confianza 22
6.2.3. Curva Precisión – Recall 22
6.2.4. Curva Recall – Confianza 23
6.2.5. Matriz de confusión 24
6.3. Entrenamiento sin SAM 25
6.3.1. Curva F1-Confidence 25
6.3.2. Curva Precisión – Recall 26
6.3.3. Curva Recall-Confidence 27
6.3.4. Matriz de confusión 27
6.4. Comparación de Modelos 28

7. Conclusión **29**

8. Cronograma de Actividades **31**

Índice de figuras

4.1. Skin Cancer MNIST: HAM10000-Kaggle 13
4.2. Imagenes de Skin Cancer MNIST: HAM10000-Kaggle 14
4.3. Preprocesamiento Con SAM 15
4.4. Preprocesamiento Sin SAM 15

6.1. Análisis por clases 19
6.2. Curva F1 en función del umbral de confianza. 21
6.3. Precisión en función del umbral de confianza. 22
6.4. Relación Precisión – Recall (área bajo la curva aproximada por mAP@0.5). 23
6.5. Recall en función del umbral de confianza (falsos negativos). 24
6.6. Matriz de confusión 25
6.7. Curva F1-Confidence Sin SAM 26
6.8. Curva Precisión – Recall 26
6.9. Curva Recall-Confidence Sin SAM 27
6.10. Matriz de confusión 27

Índice de tablas

2.1. Comparativa de métodos recientes para la detección de Cáncer de Piel . . 10

6.1. Métricas de detección por clase 18
6.2. Métricas de detección por clase 20
6.3. Comparación de rendimiento entre modelo automatizado (con SAM) y modelo manual (sin SAM). 28

8.1. Cronograma - Fase 1: Preparación y entrenamientos (4 semanas) 31
8.2. Cronograma - Fase 2: Evaluación, comparación y entrega (2 semanas) . . . 31

Capítulo 1

Marco metodológico

1.1. Introducción

El cáncer de piel representa uno de los tumores con mayor incidencia en seres humanos, siendo su pronóstico de curación altamente dependiente de una detección precoz. En la búsqueda de optimizar este diagnóstico, diversos estudios han demostrado la superioridad de las redes neuronales sobre los métodos de evaluación convencionales. Arquitecturas de detección como YOLO han logrado un excelente equilibrio entre velocidad de procesamiento en tiempo real y precisión ; sin embargo, su aplicación en el ámbito dermatológico se enfrenta a un desafío técnico crítico: las bounding boxes rectangulares tradicionales capturan proporciones de piel sana no útiles (ruido). Esta situación afecta gravemente el entrenamiento del modelo y ha obligado a la comunidad científica a depender de flujos de anotación manual exhaustiva o de procesos paralelos muy costosos.Para abordar esta clara oportunidad de optimización metodológica, el presente proyecto plantea evolucionar el preprocesamiento de imágenes médicas mediante la integración de la arquitectura YOLOv11 con SAM. Al aprovechar la capacidad de SAM para identificar los píxeles exactos de las anomalías de forma automatizada , se busca generar coordenadas precisas que limpien los datos antes de la clasificación, evitando así el desgaste computacional y humano.A lo largo de este documento, se detalla la implementación y entrenamiento de YOLOv11 utilizando el conjunto de datos especializado HAM10000. A través de un análisis comparativo entre el preprocesamiento manual tradicional y la arquitectura impulsada por SAM, esta investigación evalúa el rendimiento y la viabilidad de ambas rutas. El propósito final es proponer un sistema de detección robusto y eficiente que disminuya los costos de procesamiento exhaustivo y sirva como una herramienta tecnológica capaz de reducir los errores de diagnóstico asociados a la fatiga clínica

1.2. Antecedentes del problema

Diferentes estudios han demostrado la superioridad de redes neuronales sobre métodos convencionales. El trabajo de Aishwarya (Skin cancer diagnosis with yolo deep neural network) utilizó YOLOv3 y YOLOv4 con imágenes de la base de datos ISIC, logrando métricas de alta precisión promedio (mAP). Asimismo, la investigación de Oswalt Manoj en (Automatic detectionand categorization of skin lesions for early diagnosis of skin cancer using yolo v3- dcnn architecture) expone la eficacia de YOLOv3 con redes neuronales convolucionales profundas (DCNN) en el conjunto HAM10000 para generar mapas de características. A pesar del éxito de estas implementaciones, existe una gran adversidad: los *bounding boxes* rectangulares de YOLO capturan proporciones de piel no útiles (ruido), lo que afecta gravemente el entrenamiento. Para arreglarlo, se requirieron exhaustivos y matemáticamente densos procesos paralelos de extracción de color y textura para limpiar los datos antes de clasificarlos. [1, 11]

1.3. Planteamiento del problema

Las arquitecturas previas revelan una clara oportunidad de optimización en el preprocesamiento de datos. La falta de una segmentación propia en YOLO obliga a los investigadores a recurrir a la anotación manual exhaustiva (utilizando herramientas como Labelimg) o a flujos de trabajo paralelos muy costosos. La brecha metodológica actual exige evolucionar la forma de preprocesar los datos mediante la integración de modelos como el *Segment Anything Model* (SAM) con tecnologías de última generación como YOLOv11 [8, 13].

1.4. Objetivos

1.4.1. Objetivo general

Evolucionar y optimizar la detección de cáncer de piel mediante la implementación comparativa de YOLOv11, contrastando la segmentación tradicional manual por *bounding boxes* contra una arquitectura automatizada impulsada por la tecnología SAM.

1.4.2. Objetivos específicos

- Desarrollar un preprocesamiento automático con SAM capaz de clasificar por píxeles las áreas anómalas y generar coordenadas precisas para *bounding boxes*.

- Implementar y entrenar modelos YOLOv11 utilizando el dataset HAM10000 [14] para clasificación de lesiones.
- Comparar el rendimiento de la detección entre el preprocesamiento con y sin SAM para demostrar el aumento de eficiencia [15].

1.5. Justificación

1.5.1. Impacto Social

El cáncer de piel es uno de los tumores con mayor incidencia humana, y su pronóstico de curación depende drásticamente de la detección precoz. Implementar un sistema automatizado reducirá errores de diagnóstico por fatiga clínica [3].

1.5.2. Impacto Tecnológico

Proponer el uso conjunto de YOLOv11 y SAM evita los flujos de trabajo matemáticamente densos, disminuyendo el evidente costo de procesamiento exhaustivo.

1.5.3. Impacto Educativo

La correcta explotación del dataset HAM10000 actúa como un pilar fundamental para acercar e incentivar a estudiantes de biología y medicina al mundo del *machine learning* y procesamiento de imágenes.

1.6. Alcances y limitaciones

1.6.1. Alcances

1.6.2. Limitaciones

Capítulo 2

Marco Referencial:

La comunidad científica ha explorado diversas arquitecturas. A continuación, se resume la situación actual de los métodos para detectar cáncer de piel (CP):
Mertahi en 2025 utilizó XGBoost + Transformers ViT. Destaca por su transparencia clínica y manejo de datos desbalanceados, aunque su principal limitación es el impacto ante imágenes de baja resolución. Almutairi en 2025 Empleó U-Net + Transformers Virchow2 y Nomic, obteniendo alta robustez, pero con dependencia en datos de muy alta calidad. Magdy en 2023 y Kavitha en 2024 Aplicaron KNN-PDNN y ResNet50 respectivamente para detección temprana, mostrando métricas de rendimiento sólidas pero señalando el alto costo de procesamiento y la alta dependencia de la distribución de clases. Imran en 2022 combinó VGG16, CapsNet y ResNet por votación mayoritaria. Logró tiempos eficientes, pero arrastró errores de clasificación. Aishwarya y Oswalt Manoj en 2023 Implementaron YOLOv3 y v4. Consiguieron optimización de recursos y rendimiento en tiempo real; sin embargo, sufrieron de *overfitting* por el preprocesamiento y anotación manual. [4, 2, 10, 7, 6, 1, 11]

Tabla 2.1: Comparativa de métodos recientes para la detección de Cáncer de Piel

Estudio / Modelo	**Tarea**	**Fortalezas**	**Limitaciones**
El Mertahi et al., 2025 [4] (XGBoost + ViT)	Clasificación multiclase	Transparencia clínica; alta detección de alto riesgo.	Impacto en baja resolución; dataset invalidado.
Almutairi, 2025 [2] (U-Net + Virchow2)	Diagnóstico y Clasificación	Sinergia eficiente; alta estabilidad.	Dependencia de datos de alta calidad.
Magdy et al., 2023 [10] (KNN-PDNN)	Detectar CP benigno y maligno	Alta precisión; ahorro de recursos.	Errores de clasificación; alto costo de procesamiento.
Kavitha et al., 2024 [7] (ResNet50)	Detección temprana	Eficiencia temporal; métricas sólidas.	Dependencia de distribución de clases.
Aishwarya et al. [1] (YOLOv3 y v4)	Detección de 9 tipos de CP	Clasificación múltiple en tiempo real.	Anotación manual exhaustiva.
Oswalt Manoj et al. [11] (YOLOv3 + DCNN)	Categorización de lesiones	Alta sensibilidad y especificidad.	Dificultad en segmentación; overfitting.

Capítulo 3

Marco Teórico

3.1. Cáncer de Piel

Tumores con alta incidencia en seres humanos. Es prevenible y curable en su mayoría. El cáncer de piel se divide en **no melanoma** (carcinoma basocelular y espinocelular) y **melanoma** (originado en melanocitos, altamente peligroso si no se detecta a tiempo) [9]. Su diagnóstico clínico inicial se apoya en el método ABCDE (Asimetría, Bordes, Color, Diámetro, Evolución).

Computacionalmente, nos apoyamos en **YOLOv11**, desarrollado por Ultralytics, que procesa imágenes en una sola pasada con alto equilibrio entre velocidad y precisión. Este se ejecuta sobre **PyTorch** y utiliza **CUDA** de NVIDIA para aceleración por GPU. Para el preprocesamiento, se integra **SAM** de Meta, capaz de identificar píxeles exactos de objetos en una imagen *zero-shot*.

3.2. No melanoma

Abarca neoplasias queratinocíticas (carcinoma basocelular y espinocelular) y otros tumores de menor frecuencia [9].

3.3. Melanoma

Cáncer originado en los melanocitos por el daño celular ante exposición a rayos UV. Crece descontroladamente y puede propagarse si no se detecta a tiempo.

3.4. Método ABCDE

Regla diagnóstica sencilla que evalúa Asimetría, Bordes irregulares, Color desigual, Diámetro mayor a 6 mm y Evolución del tiempo.

3.5. Yolo y Yolov11

"You Only Look Once.[es] una red neuronal de detección de patrones. La versión 11 procesa imágenes de una sola vez, logrando un excelente equilibrio entre velocidad en tiempo real y precisión [8, 5].

3.6. Ultralytics

Empresa especializada en visión artificial responsable del desarrollo de herramientas y librerías para YOLO en Python.

3.7. PyTorch y CUDA

Librería de código abierto especializada en redes neuronales profundas. Acelerada mediante CUDA, tecnología de NVIDIA que permite a las librerías comunicarse directamente con la GPU.

3.8. Segment Anything Model (SAM)

Inteligencia artificial de Meta capaz de identificar píxeles exactos para segmentar, separar o recortar objetos dentro de una imagen [12].

Capítulo 4

DESARROLLO

4.1. Dataset Skin Cancer MNIST: HAM10000 :

Contiene 10,015 imágenes dermatológicas de lesiones malignas y benignas, divididas en dos partes junto a archivos `.csv` de metadatos ideal por su balance para pruebas de clasificación con SAM. [14]
La distribución incluye:

- **Malignas/Premalignas:** Melanoma (~11 %), Carcinoma basocelular (5.1 %), Queratosis actínica (3.3 %).
- **Benignas:** Nevus melanocíticos (~67 %), Queratosis benigna (11 %), Lesiones vasculares (1.4 %), Dermatofibroma (1.1 %).

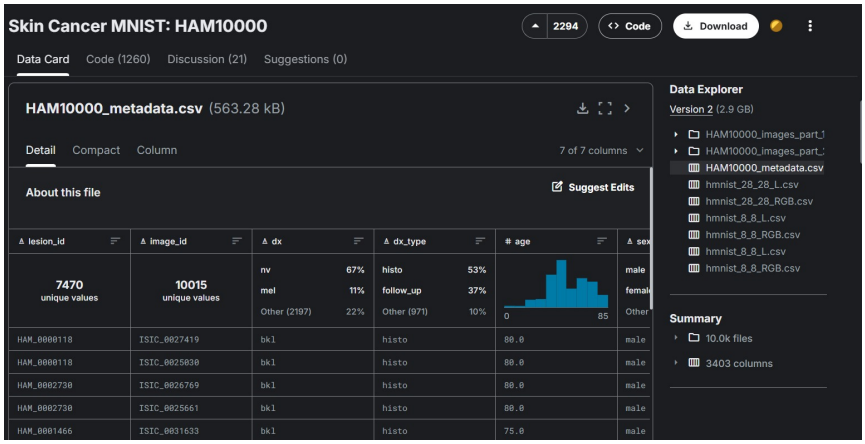

Figura 4.1: Skin Cancer MNIST: HAM10000-Kaggle

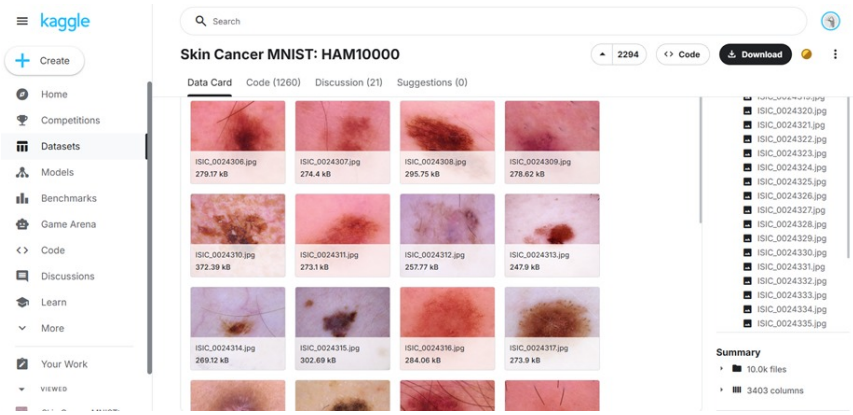

Figura 4.2: Imagenes de Skin Cancer MNIST: HAM10000-Kaggle

4.2. Representación gráfica de la idea del Proyecto

El desarrollo se estructura en dos rutas principales de preprocesamiento y entrenamiento:

4.2.1. Con SAM:

El modelo realiza un redimensionamiento de las imágenes y utiliza un *prompt* en código para obtener el punto medio y crear las máscaras de anomalías. SAM convierte los datos automáticamente a coordenadas de formato `.txt bbox` interpretables por YOLO. Finalmente, se entrena usando parámetros estandarizados e integrando técnicas de aumento de datos [13].

Figura 4.3: Preprocesamiento Con SAM

4.2.2. Sin SAM:

Se basa en capturar *bounding boxes* abarcando la imagen completa, mapeando diagnósticos binarios (0 para melanoma, 1 para el resto) y normalizando. Su entrenamiento demanda compensar la falta de exactitud ajustando manualmente los hiperparámetros de la red.

Figura 4.4: Preprocesamiento Sin SAM

Capítulo 5

Entrenamiento

El entrenamiento de Yolo se desarrolla en una simple fase en las que todas las imágenes son analizadas de un solo golpe, se maneja por épocas en las decide cuantas veces recorre una imagen para analizarla, a mayor épocas mayor entrenamiento pero también mayor necesidad de hardware.

5.1. Con SAM

El flujo de entrenamiento cuando se integra SAM parte de la carga de YOLOv11 y la asignación de los parámetros necesarios. A continuación se listan los parámetros principales y su función:

- **data:** Ruta al archivo `.yaml` que contiene la información del dataset y las clases.
- **epochs:** Número de veces que YOLO recorrerá cada imagen.
- **imgsz:** Tamaño al que se redimensionan las imágenes para YOLO (por ejemplo, `640`).
- **batch:** Cantidad de imágenes procesadas simultáneamente.
- **patience:** Número de épocas sin mejora antes de detener el entrenamiento (early stopping).
- **device:** Dispositivo donde se ejecuta el entrenamiento (CPU/GPU).
- **project:** Carpeta donde se guardan los resultados del entrenamiento.
- **name:** Nombre del experimento/carpeta de salida.

- **exist_ok:** Permite sobrescribir resultados previos si es `true`.

Para imágenes médicas es recomendable aplicar aumentos que mejoren la robustez del modelo. Ejemplos útiles:

- **flipud:** volteo vertical.
- **fliplr:** volteo horizontal.
- **degrees:** rotaciones leves.
- **hsv_s:** variación de saturación.

Una vez definidos los parámetros, se ejecuta el script de entrenamiento y se monitorea la salida hasta la finalización.

5.2. Sin SAM

El entrenamiento de YOLO sin SAM sigue la misma lógica de una sola pasada, pero requiere ajustes adicionales para compensar la menor precisión de los bounding boxes. Parámetros adicionales relevantes:

- **optimizer:** Algoritmo de optimización (ej. `SGD`, `Adam`).
- **lr0:** Tasa de aprendizaje inicial.
- **lrf:** Tasa de aprendizaje mínima al final del entrenamiento.
- **weight_decay:** Regularización para reducir overfitting.
- **cls:** Peso del término de error de clasificación.
- **box:** Peso del término de error de localización (bbox).

Con estos parámetros definidos, se lanza el entrenamiento y se espera a que finalice para evaluar métricas y ajustar hiperparámetros si es necesario.

Capítulo 6

Resultados y comparación

6.1. Evaluación de Entrenamientos

El DataSet utilizado tiene 7clases de lesiones diferentes que se tomaron en cuenta para destacar el rendimiento de los Modelos con cada uno de sus formas de procesar las imágenes.

6.2. Entrenamiento con SAM

Al finalizar los resultados por Yolo son una tabla que muestra la información la cantidad de imágenes y porcentaje de éxito que se tuvo en diferentes categorías.

Class	Images	Instances	Box(P)	Box(R)	Box(mAP50)	Box(mAP50-95)
All	512	512	0.271	0.339	0.260	0.228
Akiec	65	65	0.186	0.185	0.0874	0.0589
Bcc	99	99	0.236	0.232	0.171	0.127
bkl	99	99	0.264	0.434	0.268	0.238
Df	23	23	0.050	0.0435	0.0741	0.0638
Mel	99	99	0.251	0.338	0.204	0.171
Nv	99	99	0.275	0.283	0.200	0.174
Vasc	28	28	**0.633**	**0.857**	**0.818**	**0.762**

Tabla 6.1: Métricas de detección por clase

Cada columna representa lo siguiente:

- Images — cuántas imágenes del set de validación tienen esa clase.
- Instances — cuántas detecciones reales existen.
- Box(P) — Precisión: de todas las cajas que predijo YOLO, ¿qué porcentaje era correcto?
- R — Recall: de todas las lesiones reales, ¿qué porcentaje encontró YOLO?
- mAP50 — precisión promedio con umbral IoU de 0.5 (la métrica principal).
- mAP50-95 — promedio entre umbrales 0.5 y 0.95 (más exigente, penaliza cajas imprecisas).

El análisis por clases es el siguiente:

Figura 6.1: Análisis por clases

Tabla 6.2: Métricas de detección por clase

Class	Images	Instances	Box(P)	Box(R)	Box(mAP50)	Box(mAP50-95)
All	512	512	0.271	0.339	0.260	0.228
Akiec	65	65	0.186	0.185	0.0874	0.0589
Bcc	99	99	0.236	0.232	0.171	0.127
bkl	99	99	0.264	0.434	0.268	0.238
Df	23	23	0.050	0.0435	0.0741	0.0638
Mel	99	99	0.251	0.338	0.204	0.171
Nv	99	99	0.275	0.283	0.200	0.174
Vasc	28	28	**0.633**	**0.857**	**0.818**	**0.762**

Análisis por clase

Cada clase corresponde a una enfermedad y obtuvo resultados distintos; a continuación se destacan y describen sus métricas.

vasc — Lesiones vasculares (la estrella del modelo)
Con **mAP@0.5 = 0.818** y **recall = 0.857** el modelo detecta estas lesiones excelentemente. La razón es visual: las lesiones vasculares presentan un color rojo/púrpura muy distintivo frente a la piel; SAM las segmenta mejor por el alto contraste y bordes definidos.

bkl — Queratosis benignas (resultado aceptable)
mAP = 0.268, **recall = 0.434**. Son lesiones con textura rugosa relativamente distinguible; es la segunda clase más fácil para el modelo después de *vasc*.

mel — Melanoma (resultado modesto)
mAP = 0.204, **recall = 0.338**. Preocupante clínicamente, ya que el melanoma es la clase más peligrosa. Visualmente se parece a los nevos (*nv*) y a queratosis seborreicas, lo que genera confusión.

nv — Nevos melanocíticos (lunares comunes)
mAP = 0.200. Muy similar a *mel*, lo que confirma que el modelo confunde frecuentemente melanoma con nevo benigno — el error más crítico en un contexto clínico.

bcc — Carcinoma basocelular
mAP = 0.171. Estas lesiones muestran apariencia variable según estadio, lo que dificulta el aprendizaje cuando hay pocas imágenes representativas.

akiec — Queratosis actínica

mAP = 0.087. Valor muy bajo; son lesiones sutiles con bordes difusos que SAM probablemente segmentó con ruido en varios casos, afectando el entrenamiento.

df — Dermatofibroma (el peor resultado)
mAP = 0.074, **recall ≈ 0.044**. Solo 23 imágenes en validación: el modelo casi no aprendió esta clase por falta de ejemplos. Con tan pocas muestras YOLO no puede generalizar adecuadamente.

6.2.1. Curva F1 – Confianza

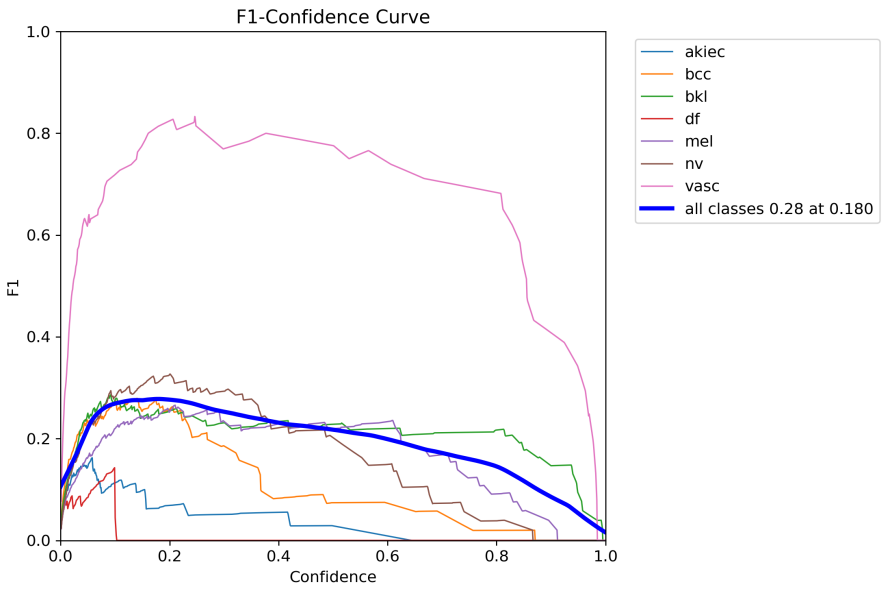

Figura 6.2: Curva F1 en función del umbral de confianza.

Esta gráfica presenta los resultados sobre la confianza del modelo y la relación entre precisión y recall. La línea azul gruesa muestra la media de todas las clases, que se sitúa aproximadamente entre **0.2** y **0.3**. El modelo mantiene una alta confianza para las **lesiones vasculares**, con valores cercanos a **0.8**. Las clases **bkl**, **nv**, **mel** y **bcc** presentan curvas similares, centradas entre **0.2** y **0.4**, con numerosos picos que indican **inestabilidad** y baja seguridad al clasificar estas lesiones. Las clases **akiec** y **df** muestran una subida inicial seguida de un desplome al exigir mayor confianza, lo que sugiere que el modelo no predice consistentemente estas clases cuando se requiere mayor certeza.

6.2.2. Curva Precisión – Confianza

La gráfica muestra el porcentaje de detecciones correctas frente a falsos positivos. En el punto medio de exigencia de confianza, la precisión alcanza aproximadamente **0.4** (40 %), lo que implica que cerca de **6 de cada 10** detecciones podrían ser falsos positivos, una cifra preocupante para aplicaciones médicas.

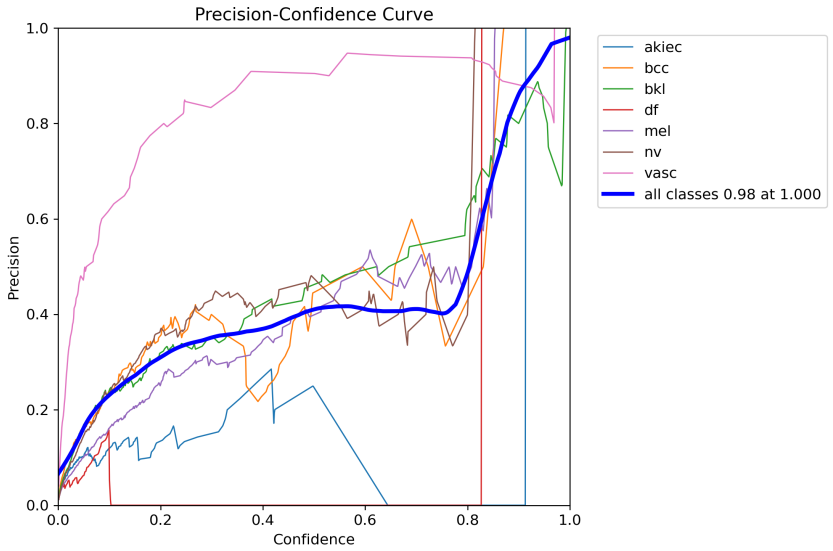

Figura 6.3: Precisión en función del umbral de confianza.

6.2.3. Curva Precisión – Recall

Esta gráfica muestra la relación entre falsos positivos y falsos negativos; el área bajo la curva se aproxima al **mAP@0.5**. La caída pronunciada en la mayoría de las clases indica que la precisión empeora rápidamente al intentar aumentar el recall, sin un umbral que permita detectar la mayoría de los cánceres sin multiplicar los falsos positivos.

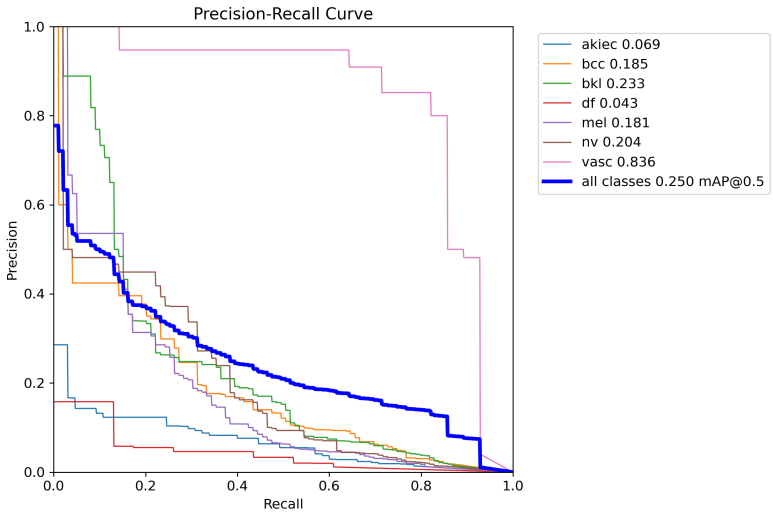

Figura 6.4: Relación Precisión – Recall (área bajo la curva aproximada por mAP@0.5).

6.2.4. Curva Recall – Confianza

Esta curva es crítica en el ámbito médico porque refleja los **falsos negativos**. Al exigir mayor confianza, el recall cae de forma pronunciada desde el inicio, lo que demuestra una baja seguridad para evitar falsos negativos (clasificar como sano lo que es enfermedad). El recall promedio global es aproximadamente **0.71**, lo que indica que alrededor del **29 %** de las lesiones no son detectadas por el modelo.

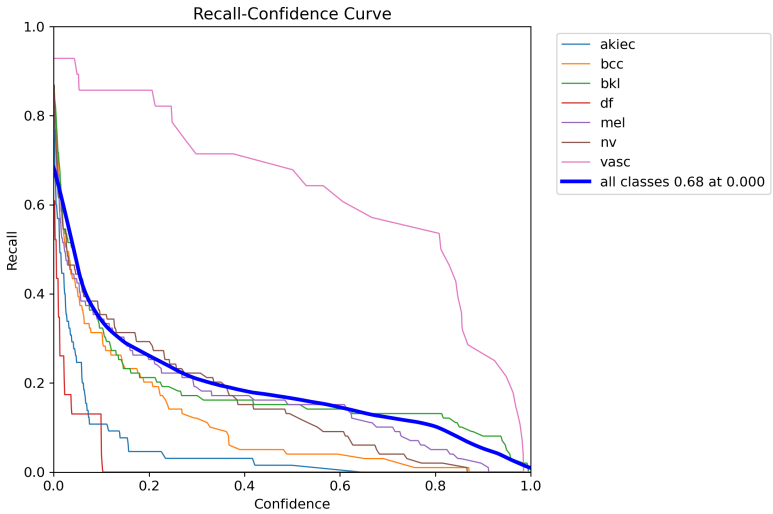

Figura 6.5: Recall en función del umbral de confianza (falsos negativos).

6.2.5. Matriz de confusión

La matriz de confusión muestra con precisión en qué se equivoca el modelo y con qué clases confunde cada lesión. En el eje **X** se representan las **clases reales** y en el eje **Y** las **clases predichas** por el modelo. El fondo oscuro de la última fila (background) evidencia un problema grave: en varias clases el modelo prácticamente no detecta nada, lo que se refleja en valores bajos en la diagonal principal. Además, la matriz revela una gran cantidad de **falsos positivos**, es decir, detecciones que el modelo marca como patológicas cuando en realidad no lo son. También se observa que, en muchos casos, aunque el modelo detecta la presencia de una lesión, la **clasifica incorrectamente** (por ejemplo, confundir *mel* con *nv*). Esto resulta en un sistema ineficiente e inseguro para aplicaciones médicas, ya que combina una alta tasa de falsos positivos con errores de clasificación que pueden conducir a diagnósticos erróneos o a la omisión de casos críticos.

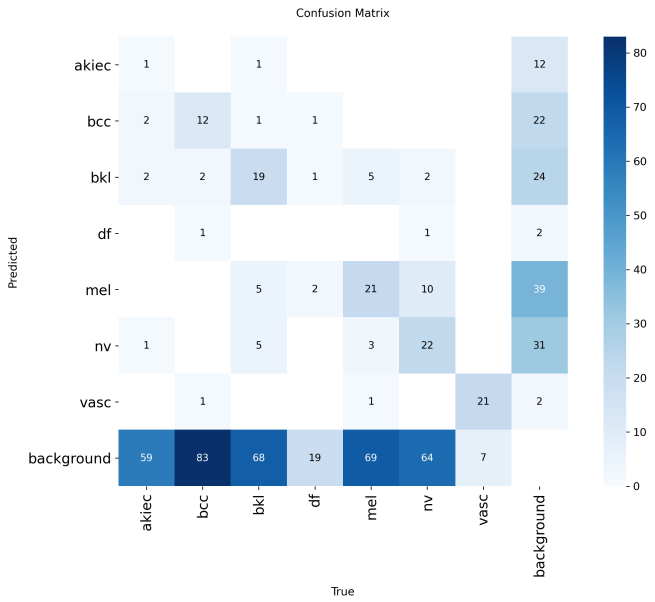

Figura 6.6: Matriz de confusión

6.3. Entrenamiento sin SAM

6.3.1. Curva F1-Confidence

Las clases en esta grafica se mantiene en un 0.80 una cifra excelente que muestra un fantástico rendimiento en general de los datos. Otra cosa a destacar es la constancia en los datos mostrando pocos picos y manteniendo su valor, dando a entender un modelo con un valor fijo de confianza.

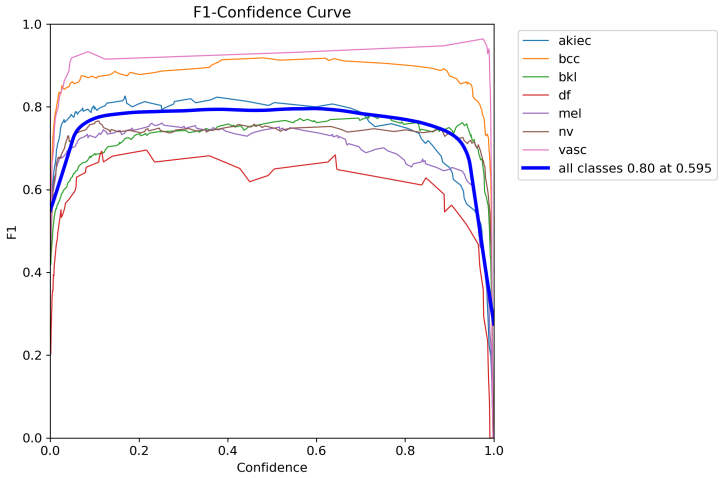

Figura 6.7: Curva F1-Confidence Sin SAM

6.3.2. Curva Precisión – Recall

La grafica muestra un área bajo la curva de 0.876 que nos da un mAP@0.5 de casi un 88 % dando una precisión altísima en la que casi no permite falsos positivos y tampoco permite que lesión se le pasen.

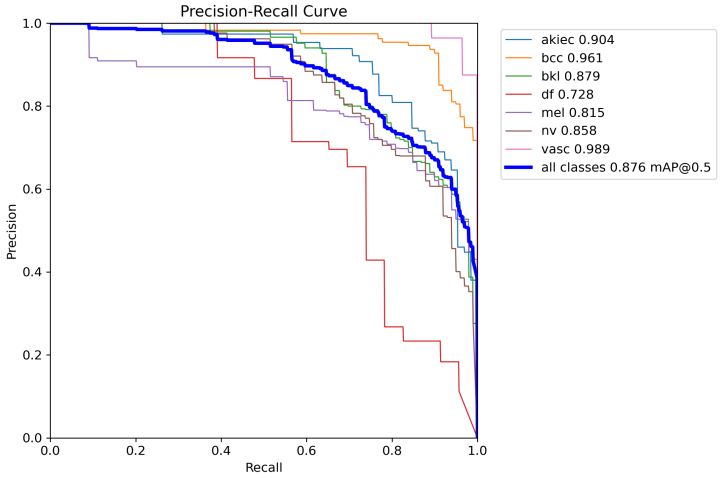

Figura 6.8: Curva Precisión – Recall

6.3.3. Curva Recall-Confidence

La grafica demuestra un excelente rendimiento en los Falsos Negativos, ose que prácticamente no permite que se le escape alguna ninguna imagen que pueda ser una posible amenaza.

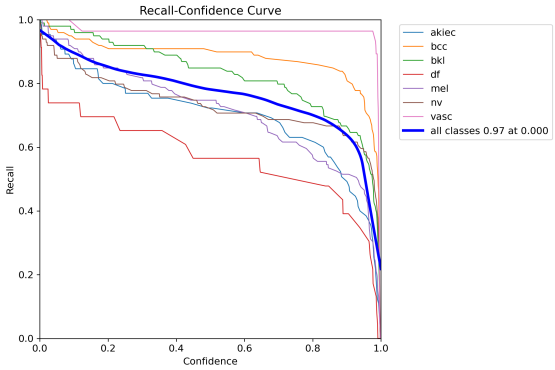

Figura 6.9: Curva Recall-Confidence Sin SAM

6.3.4. Matriz de confusión

La matriz muestra un excelente rendimiento en la clasificación de las enfermedades dando por echo la versatilidad, confiabilidad y seguridad del modelo. Dando pocas o directamente nulas casillas en las que la detección fue incorrecta y mostrando gran cantidad de acierto en cada una de ellas.

Figura 6.10: Matriz de confusión

6.4. Comparación de Modelos

La siguiente tabla destaca los resultados más importantes y los compara entre ambos modelos: el **Modelo con SAM (Automatizado)** y el **Modelo Manual (Sin SAM)**. Los valores resumen métricas clave de detección y clasificación obtenidas en el conjunto de validación.

Tabla 6.3: Comparación de rendimiento entre modelo automatizado (con SAM) y modelo manual (sin SAM).

Métrica	**Modelo con SAM (Automatizado)**	**Modelo Manual (Sin SAM)**
mAP@0.5 (Global)	0.260	0.876
F1-Score máximo	0.29 (a 0.19 de confianza)	0.80 (a 0.59 de confianza)
Recall máximo	0.71	0.97
Acierto en Melanoma	22 %	71 %
Acierto en Carcinoma (BCC)	18 %	89 %
Ceguera (Background)	+60 %	0 %

En resumen, la tabla muestra que el **modelo manual** supera al modelo automatizado en la mayoría de las métricas críticas (mAP, F1 máximo y recall), así como en la detección específica de clases clínicas relevantes (melanoma y BCC). Por su parte, el **modelo con SAM** presenta una tasa elevada de *background* (ceguera) y un rendimiento global inferior en mAP, lo que sugiere que la segmentación automática no fue suficiente para compensar problemas de anotación, balance de clases o ajustes de hiperparámetros en este experimento.

Recomendaciones para trabajos futuros

- Revisar y normalizar las anotaciones generadas por SAM para reducir ruido en las máscaras.
- Aumentar muestras o aplicar técnicas de oversampling para clases con pocos ejemplos (por ejemplo, *df*).
- Afinar hiperparámetros (learning rate, augmentaciones, pesos de pérdida por clase) en el flujo con SAM.
- Evaluar métricas por clase y curvas ROC/PR adicionales para entender mejor los trade-offs entre precisión y recall.

Capítulo 7

Conclusión

El entrenamiento de ambos modelos mostró resultados marcadamente distintos; la diferencia principal entre ellos fue el **preprocesamiento**, que fue la única variable modificada entre los experimentos.

La implementación de SAM como generador automático de bounding boxes puede ser una vía válida de automatización; sin embargo, la forma en que segmenta las imágenes provocó problemas significativos en el rendimiento de YOLO. La causa principal de este fracaso fue la **pérdida del contexto de la imagen** (piel no afectada alrededor de la lesión). Al eliminar ese contexto, durante el entrenamiento el modelo no dispone de información suficiente para distinguir entre *melanoma* y piel sana: SAM segmenta y entrega únicamente el área de la mancha, por lo que la imagen resultante se interpreta como la visión completa del modelo. Esto dificulta la discriminación entre la lesión y su entorno, dejando al detector con diferencias muy sutiles que no bastan para una clasificación fiable.

Esto no implica que SAM haga un mal trabajo de segmentación: SAM segmenta correctamente el área solicitada. El problema es que, para la tarea de detección y clasificación con YOLO, el contexto circundante es informativo y necesario. Al perderse ese contexto, YOLO no puede aprender correctamente qué partes de la imagen son relevantes y cuáles deben ignorarse.

Por el contrario, el modelo entrenado sin la aplicación de SAM obtuvo resultados superiores y más confiables. Aunque en ese caso las bounding boxes abarcan una porción mayor de la imagen, ese enfoque conserva el contexto necesario para que YOLO distinga entre el área de interés y el fondo, lo cual resulta crítico para la clasificación clínica.

Futuras Recomendaciones

- No usar las máscaras de SAM de forma directa como única fuente de anotación;

combinar las máscaras con el contexto original (por ejemplo, expandiendo las BBox o conservando un margen de piel sana alrededor de la lesión).

- Revisar y limpiar las anotaciones automáticas generadas por SAM para reducir ruido y falsos positivos.
- Aumentar el número de muestras para clases escasas (por ejemplo, *df*) o aplicar técnicas de oversampling/augmentación específicas.
- Ajustar pesos de pérdida por clase y otros hiperparámetros (learning rate, augmentaciones) para compensar el desbalance y la heterogeneidad visual.
- Evaluar flujos híbridos: usar SAM para proponer candidatos y luego validar/ajustar las BBox mediante reglas heurísticas o anotación humana mínima.

En resumen, la automatización del preprocesamiento con SAM tiene potencial, pero requiere un diseño cuidadoso que preserve el contexto visual y controle la calidad de las anotaciones para que YOLO pueda aprender de forma robusta y segura en un entorno clínico.

Capítulo 8

Cronograma de Actividades

Tabla 8.1: Cronograma - Fase 1: Preparación y entrenamientos (4 semanas)

Actividad	**Sem 1**	**Sem 2**	**Sem 3**	**Sem 4**
Planificación inicial y preparación del entorno	X			
Revisión y limpieza del dataset (HAM10000)	X	X		
Generación de máscaras con SAM (preprocesamiento)		X	X	
Revisión y corrección manual de máscaras / anotaciones		X	X	
Generación de BBox y creación de archivos .yaml para YOLO			X	
Entrenamiento **con SAM** (configuración y ejecución)			X	X
Inicio de entrenamiento **sin SAM** (anotación manual / baseline)				X

Tabla 8.2: Cronograma - Fase 2: Evaluación, comparación y entrega (2 semanas)

Actividad	**Sem 5**	**Sem 6**
Finalización de entrenamiento **sin SAM**	X	
Evaluación y extracción de métricas (mAP, precision, recall, curvas)	X	
Comparación de resultados y análisis por clase	X	X
Generación de figuras (curvas, matriz de confusión)	X	X
Redacción de resultados, conclusiones y recomendaciones		X
Revisión final, formato y entrega del informe		X

Bibliografía

[1] N. Aishwarya, K. Manoj Prabhakaran, F. Tsegaye Debebe, M. Sai Sree Akshitha, and P. P. Reddy. Skin cancer diagnosis with yolo deep neural network. *Procedia Computer Science*, 220:651–658, 2023.

[2] K. Almutairi. Skin cancer classification using u-net and transformers. *Estado del Arte - Documento Interno*, 2025.

[3] I. E. Astudillo, G. V. Santis, F. E. Astudillo, and P. V. Mora. ¿nos sentimos en riesgo? percepción comunitaria del cáncer de piel en zonas de alta radiación ultravioleta. *Piel*, 2026.

[4] A. El Mertahi et al. Hybrid models for multiclass skin cancer classification. *Estado del Arte - Documento Interno*, 2025.

[5] L. Hakim et al. Identifying skin cancer disease types with you only look once (yolo) algorithm. *Repository UNKRIS*, 2021.

[6] M. Imran et al. Automated decision of skin cancer utilizing vgg16, capsnet and resnet. *Estado del Arte - Documento Interno*, 2022.

[7] S. Kavitha et al. Early detection of skin cancer using resnet50. *Estado del Arte - Documento Interno*, 2024.

[8] R. Khanam and M. Hussain. Yolov11: An overview of the key architectural enhancements, 2024.

[9] B. P. Lobos and S. A. Lobos. Cáncer de piel no-melanoma. *Revista Médica Clínica las Condes*, 22(6):737–748, 2011.

[10] S. Magdy et al. Detecting and classifying skin cancer with knn-pdnn. *Estado del Arte - Documento Interno*, 2023.

[11] S. Oswalt Manoj, K. Rama Abirami, A. Victor, and M. Arya. Automatic detection and categorization of skin lesions for early diagnosis of skin cancer using yolo-v3 - dcnn architecture. *Image Analysis & Stereology*, 42:101–117, 2023.

[12] Y. Qiao et al. Biseg-sam: Weakly-supervised post-processing framework for boosting binary segmentation in segment anything models. *arXiv preprint*, 2025.

[13] M. Reis et al. Yolosamic: A hybrid approach to skin cancer segmentation with the segment anything model and yolov8. *Diagnostics*, 2025.

[14] P. Tschandl, C. Rosendahl, and H. Kittler. The ham10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5:180161, 2018.

[15] I. Zaqout et al. Foundation-model-driven skin lesion segmentation and classification using sam-adapters and vision transformers. *Diagnostics*, 2025.